

PoC 技術検証 ご報告

変圧器オイル温度（OT）の将来予測による 予防保全活用可能性の検証

ETT（Electricity Transformer Temperature）データセットを用いた
機械学習モデルの構築・比較分析

株式会社Athena Technologies 御中

四国大学文学部書道文化学科3年 岡野 菜月

検証結果の要点

シンプルな手法で実用十分な精度を確認。
予防保全システムへの実装検討に進める段階にあると考える

最良モデル

LinearRegression

RMSE

0.65 °C

1時間先のOT予測誤差（検証データ）

深層学習モデル（LSTM系）2種を
上回る精度

モデル	RMSE（°C）	複雑さ
LinearRegression（線形回帰）	0.65	低
SimpleLSTM	0.85	中
UNetResidualLSTMBlock	0.85	高

解釈：

- ・ 本データでは「直前のOTに強く依存する」自己回帰的な性質が強く、複雑な深層学習モデルの優位性は確認できなかった。
- ・ 計算コスト・解釈性の観点でも線形回帰は運用導入に有利。

検証の目的

「予測に基づく予防保全」への移行可能性を、 公開データセットでの再現性検証から確認する

背景・課題

- 変圧器のオイル温度は、設備劣化・事故リスクと密接に関係する重要指標
- 従来は経験則に基づく閾値監視が中心で、負荷変動等による温度変動の複雑化に対応しづらい
- 事後対応型の保全から、予測に基づく予防保全へ移行したい

本 PoC の検証内容

公開ベンチマーク ETT データセットを用いて、

1時間先のオイル温度（OT）

を予測することで、運用・保全判断にどの程度価値を出せそうかを検証する

前提条件

$t = T$ の予測時、 $t = T$ 時点の特徴量（負荷指標等）は使用可能なものとして設計

データ概要

約2年分・欠損なしの時系列データ。
OTは季節性と日次変動の両方を持つ

データ件数

17,420 時点

欠損値

0 件


観測期間

**2016/07-
2018/06**

OT 平均

13.3 °C

OT の時系列推移（概形）




観察ポイント

- 2016年夏に最高値（約46°C）を記録し、その後低下傾向
- 季節（年次）・日内（時間帯）の周期的変動が見られる
- 値域は -4.1°C～46.0°Cと振れ幅が大きい

負荷指標とOTの相関は弱く、 単独の負荷データだけではOTを十分説明できない

各負荷指標とOTの相関係数



相関データの解釈

- 最も相関が高いHULL/MULLでも係数は0.22程度と弱め
 - 負荷指標（瞬時値）だけではOTの変動を説明しにくい
- 「過去のOT自体」を特徴量として活用する余地が大きいと判断

EDAの考察 ②

一部の負荷指標は互いに強く相関しており、
特徴量間の情報の重複（多重共線性）が存在する

負荷指標	相関係数	解釈
HUFL × MUFL	0.99	高圧・中圧の有効負荷はほぼ同じ動き
HULL × MULL	0.93	高圧・中圧の無効負荷も強く連動
LUFL × LULL	0.33	低圧側は比較的独立した変動

データからの解釈：

HUFL/MUFL、HULL/MULLはほぼ同一の情報を持つため、特徴量をそのまま並列投入しても精度向上に直結しにくい。モデルの複雑さを上げる前に、まず「効果が見込める特徴量」を見極めることが重要と判断した。

EDA全体の結論

- ① 負荷指標単独の説明力は弱い
- ② 負荷指標間には強い重複がある
- ③ 自己回帰的特徴量（直前OT等）の活用が有効と推察

「複雑さに対して精度がどう変化するか」を検証するため、
3段階でモデルを比較する設計とした

01

LinearRegression

自己回帰特徴量を含む
ベースラインモデル

02

SimpleLSTM

時系列の時間依存性を
捉える基本的なLSTM

03


UNetResidualLSTMBlock

U-Net型の構造に
残差接続を組み合わせたLSTM

モデル構築の過程

「直前のOT」を特徴量に加えるだけで、
予測誤差は約200分の1に改善した

MSE の変化（標準化前スケール）




特徴量追加の効果

- 負荷指標のみ（Baseline）
 - MSE 83.66 と精度が低い
- OT_lag1（1時間前のOT）を追加
 - MSE 0.42 へ急改善
- 時間帯・移動平均を追加
 - わずかに改善、効果は限定的

モデル構築の結果

3モデルを公平な条件で比較した結果、 線形回帰が最も高い精度を示した

検証データでのRMSE (°C・低いほど良い)



各モデルの精度

- 線形回帰
 - RMSE 0.65°Cで最良
 - SimpleLSTM
 - RMSE 0.85°C
 - UNetResidualLSTMBlock
 - RMSE 0.85°C

(最も複雑だが精度は最良ではない)
- ※ 深層学習モデルには学習率スケジューラ・
Early Stoppingを共通適用し、比較条件を統一

「深層学習が不要」ではなく、 「本データの時間スケールでは単純な手法が優位」という結果

線形回帰が優位だった理由

- OTの変動は「直前の値」に強く依存する自己回帰的な性質を持つ
- 1時間先という短い予測対象では、複雑な非線形性を捉える必要性が小さい
- LSTM系モデルが本来得意とする「長期の時系列パターン」が、本タスクでは活きにくい

一般化への注意

- 本結果は「深層学習が不要」という一般的な結論ではない
- 「本タスクの時間スケール・データ量においては、シンプルな手法が優位だった」という限定的な知見
- 予測対象期間を延ばす、データ量を増やす等の条件下では結論が変わる可能性がある

「公平に比較できる」検証設計にすることに特に重点を置いた

1 段階的な比較設計

線形回帰 → SimpleLSTM → UNetResidualLSTMBlock の順に複雑さを上げ、「複雑さに対して精度がどう変化するか」を検証できる設計とした

2 目的変数のスケーリング

説明変数だけでなく目的変数（OT）も標準化し、勾配の更新が適切なスケールで行われるようにした

3 学習の安定化

勾配クリッピング・学習率スケジューラ（ReduceLROnPlateau）
・ Early Stoppingを導入し、過学習や学習停滞を防止

4 評価指標の単位統一

学習中は標準化スケールのMSEを使用し、最終比較は元の℃スケールに逆変換して線形回帰と公平に比較

実運用を見据えると、予測期間の拡張とデータ規模の検証が次の論点になる

現時点での限界

- ハイパーパラメータ探索不足
 - window_size ▪ hidden_dim等は試行的な値で
網羅的探索は未実施
- 予測対象が「1時間後」に限定
 - 実運用ではより長期（数時間～数日先）の予測が必要
- データ規模（約14,000サンプル）
 - 複雑な深層学習モデルの強みが十分発揮されない
規模の可能性

今後の改善方針

- 多段階予測への拡張
 - 数時間～数日先の予測タスクで再評価
- ハイパーパラメータの網羅的探索
 - LSTM系モデルの精度改善余地を検証
- データ拡充
 - 規模を増やした場合の再検証
- 運用コストも踏まえた選定
 - 精度に加え、計算コスト・解釈性も評価軸に含める

まとめ・ご提案

シンプルな手法の有効性が確認できた今が、
予防保全システムの実装検討に進む好機と考える

Step 1

短期

線形回帰モデルでの
PoC拡張・実データ検証

Step 2

中期

多段階予測・他変圧器
データでの汎化性検証

Step 3

長期

予防保全システムへの
組み込み・運用設計

ご質問・ご議論等、お気軽にお声がけください。